


Te pedimos que utilices la plataforma BigML, tal como se ha explicado en el caso práctico del primer capítulo de esta unidad. Se da por sentado que sabes acceder, y que tienes usuario para trabajar en ella. Tendrás que entregar un documento con la siguiente información:

Apartado 1: Localiza el dataset "Diabetes completo (spanish)":


- Utiliza el buscador de datasets que tiene la propia plataforma para ello.

Entro a la plataforma y me hago una cuenta.




- Incorpora una captura de pantalla del dataset mencionado incorporado a tu apartado Datasets.

Me costó un poco encontrarlo.




Dado que es free, lo añado a mis Datasets.



Apartado 2: Observación del dataset:


- Incorpora una captura de pantalla del dataset donde se vean al menos 10 categorías con sus tipologías, errores, histogramas, etc.

Visualizo el dataset con al menos 10 categorías.



- Explica cómo es el dataset: Número de instancias y número de categorías.

Visualizando el dataset podemos ver que contiene **768 instancias** (columna Count) y **16 categorías**. En la imagen se puede ver un pequeño gráfico donde se muestra la distribución de los valores de las variables numéricas.



- Explica el tipo de categorías (numéricas, texto, items, categóricas...).

Los datos se organizan en diferentes categorías como: Embarazos, Glucosa... y cada una de ellas tiene un tipo de dato específico. Veámoslos uno por uno:

- **1 2 3**: Es un campo numérico y es el 'id' que se utiliza en la API.

Name	Type	Count	Missing	Errors	Histogram
Embarazos	1 2 3	768	0	0	
Glucosa	1 2 3	768	0	0	

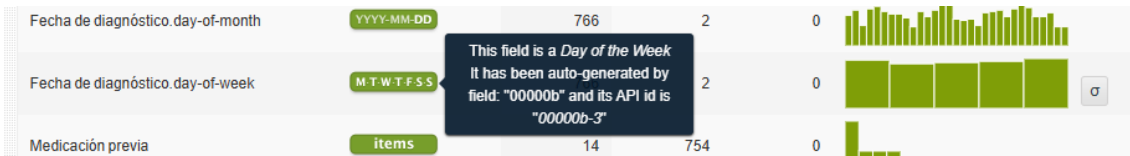
- **A B C**: Es un campo categórico y es el identificador que se utiliza en la API. Categórico quiere decir que contiene valores que representan categorías o grupos. Como por ejemplo valores "Sí" o "No" ...

Diabetes	A B C	768	0	0	
Fecha de diagnóstico	YYYY-MM-DD	768	0	0	START: Not available END: Not available

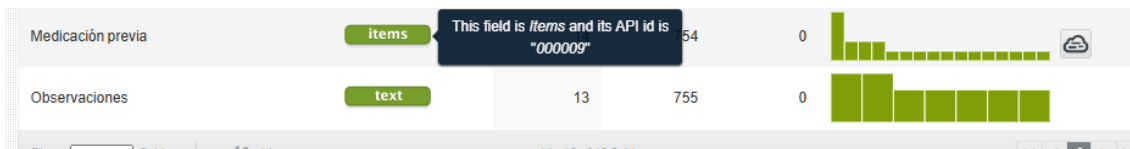
- **YYY-MM-DD**: Indica que este campo es de tipo fecha y tiene un id único en la API. El formato de la fecha es **año-mes-día**.

Fecha de diagnóstico	YYYY-MM-DD	768	0	0	START: Not available END: Not available
Fecha de diagnóstico year	YYYY-MM-DD	768	0	0	

- **M-T-W-T-F-S-S:** Este campo indica que este campo representa un día de la semana y que ha sido generado automáticamente, y que tiene un identificador en la API.




- **items:** Este campo indica que se refiere a una lista de elementos relacionados, por ejemplo, en un dataset médico, podría ser una lista de medicamentos. Además tiene un identificador en la API.



- Analiza los histogramas de cada categoría y comenta aquellos en los que consideres que hay algún tipo de anomalía.

Viendo la gráfica entre edad y embarazos, me llama la atención esto:



No se si lo entiendo bien, creo que significa que hubo 9 embarazos en personas de 81 años.


Y por comentar otra cosa, los datos son de 2016.



Apartado 3: Preparación del dataset para entrenamiento y test:

- Incorpora una captura de pantalla del proceso en el que defines los porcentajes de datos reservados para entrenamiento y para test.

Entramos en la zona de training.



Lo dejo por defecto y lo ejecuto.

Diabetes completo (spanish) |

bigml.com/dashboard/dataset/67d22ba372b06d7691c5d801

Aplicaciones

PRODUCT • GETTING STARTED • PRICING • SUPPORT

ADIEGUEZALVA... Dashboard

ADIEGUEZALVAZ - My Dashboard

Sources Datasets Supervised Unsupervised Predictions Tasks WhizzML

Diabetes completo (spanish) | Training (80%)



Processing...

Your source is being processed and we'll generate a dataset soon

COMPANY • PROJECTS • RESULTS • TRAINING • GALLERY

ALBERTO DIEGUEZ ALVAREZ

Perfil de usuario

Página Principal Área personal

Perfil



ALBERTO DIEGUEZ ALVAREZ

Cursos Detalles

Detalles de usuario

Editar perfil

Dirección de correo

a.dieguez.alvar...ez@gmail.com

Sede_marzo_2025

España - Valladolid

Miscelánea

Entradas del blog

Mensajes en foros

Foros de discusión

Planes de aprendizaje

Diabetes completo (spanish) |

bigml.com/dashboard/dataset/67d22ba372b06d7691c5d801

Aplicaciones

PRODUCT • GETTING STARTED • PRICING • SUPPORT

ADIEGUEZALVA... Dashboard

ADIEGUEZALVAZ - My Dashboard

Sources Datasets Supervised Unsupervised Predictions Tasks WhizzML

Diabetes completo (spanish) | Training (80%)

Name	Type	Count	Missing	Errors	Histogram
Embarazos	1,2,3	614	0	0	
Glucosa	1,2,3	614	0	0	
Presión sanguínea	1,2,3	614	0	0	
Plaque cutáneo	1,2,3	614	0	0	
Insulina	1,2,3	614	0	0	
Índice de masa corporal	1,2,3	614	0	0	
Padrón diabetes	1,2,3	614	0	0	
Edad	1,2,3	614	0	0	
Diabetes	A,B,C	614	0	0	
Medicación previa	Items	12	602	0	
Observaciones	Text	11	603	0	
Fecha de diagnóstico	YYYY-MM-DD	612	2	0	
Fecha de diagnóstico year	YYYY-MM-DD	612	2	0	

COMPANY • PROJECTS • RESULTS • TRAINING • GALLERY

ALBERTO DIEGUEZ ALVAREZ

Perfil de usuario

Página Principal Área personal

Perfil



ALBERTO DIEGUEZ ALVAREZ

Cursos Detalles

Detalles de usuario

Editar perfil

Dirección de correo

a.dieguez.alvar...ez@gmail.com

Sede_marzo_2025

España - Valladolid

Miscelánea

Entradas del blog

Mensajes en foros

Foros de discusión


Planes de aprendizaje

Informes

Apartado 4: Entrenamiento:


- Incorpora una captura de pantalla que muestre el árbol de decisión del modelo ya entrenado.

Genero el árbol.



- Explica los principales resultados: Casos en los que haya resultado positivo o negativo con suficiente confiabilidad.

Para ello ajusto el “confidence” entre 80% y 100%



Diabetes completo (spanish) | bigml.com/dashboard/models/67d226a25d5427c052a90952

ALBERTO DIEGUEZ ALVAREZ: P...

Diabetes: No 95.95%

PREDICTOR: 0.18 14.83 Predictions for Diabetes 80 CONFIDENCE 100

Edad <= 28.00

Índice de masa corporal <= 31.00

Plegueo cutáneo <= 31.00

Embarazos <= 2.00

No


No

Confianza: 95.95%

91 instancias


14.62% of data

Ajusto el “confidence” y pongo diabetes sí.





- Incorpora capturas de pantalla de los diagramas de confiabilidad (confidence) y predicción (prediction).

Estos son de confiabilidad, hay varias formas de verlo.




Y estos de probabilidad.



Apartado 5: Evaluación:


- Incorpora una captura de pantalla en la que se muestre la evaluación del modelo entrenado realizada con el dataset reservado en el apartado 3.

Evaluando el modelo.




- Explica el resultado de dicha evaluación, indicando el nivel de confianza obtenido (Accuracy) y el nivel de precisión (Precision).

Como podemos ver en la foto tenemos un 70.13% de fiabilidad y un 68.60 % de precisión.




También haciendo cálculos veo que hubo falsos positivos.



Haciendo los cálculos de los que han sido falsos positivos nos da 38,33%.

También se puede ver aquí.



Conclusiones:

Para ser un dataset pequeño no está mal, pero para mi gusto tiene poca fiabilidad y precisión.