

Utiliza uno de los modelos que ya has entrenado en BigML en las unidades anteriores, y evalúa los resultados de las predicciones sobre los datos de test utilizando la matriz de confusión.

Apartado 1: Realiza una predicción por lote en BigML

- Elige un dataset para clasificación binaria de los que vienen por defecto en BigML o carga uno que te parezca interesante.
- Separa los datos en 80% para el entrenamiento y 20% para test.


Escojo el dataset de la tarea anterior y se separan los datos.

The screenshot displays the BigML dashboard for user ADIEGUEZALVAREZ. The main area shows a list of datasets under the 'Datasets' tab. The 'Diabetes completo (spanish)' dataset is highlighted, showing it has been split into a Training set (80%) and a Test set (20%). The right sidebar shows the user's profile, including their name, a profile picture, and a list of courses, with 'Big Data Aplicado (24-25)' being the current course.

- Entrena un modelo de árbol de decisión.


Voy al apartado de evaluación y genero el árbol de decisión.

The screenshot shows the BigML dashboard for user CHIDDOESP. The main area displays a decision tree model trained on the 'Diabetes completo (spanish)' dataset. The tree is visualized with nodes and branches, and a legend on the right indicates the predicted classes: 'Glucosa' (yellow) and 'Peligro diabetes' (pink). The right sidebar shows the user's profile, including their name, a profile picture, and a list of courses, with 'Big Data Aplicado (24-25)' being the current course.



- Realiza la predicción por lotes, seleccionando el conjunto de datos de test. Descarga el archivo csv resultante.


Descargo el csv. Y cargo los datos.



Apartado 2: Calcula la matriz de confusión.


- Abre el archivo csv en una hoja de cálculo y aplica las fórmulas necesarias para obtener: errores totales, falsos negativos y falsos positivos.

Después de generar las funciones, tengo los resultados.



- Construye la matriz de confusión, rellenando los valores correspondientes.

Después de realizar todas las operaciones este es el resultado.



True Class

	Positive	Negative
Predicted Class Positive	TP	FP
Negative	FN	TN

Matriz de confusión

	Verdadero Positivo (TP)	Falso Positivo (FP)
Verdadero Negativo (TN)	25	25

Verdadero positivo (TP) - Tu modelo predijo la clase positiva. Por ejemplo, identificar un correo electrónico como spam.

Negativo verdadero (NT) - Tu modelo predijo correctamente la clase negativa. Por ejemplo, identificar un correo electrónico normal como no spam.


Falso positivo (FP) - Tu modelo predijo incorrectamente la clase positiva. Por ejemplo, identificar un correo normal como spam.

- Analiza los resultados. ¿Es fiable el modelo?

- **Exactitud:**

La exactitud mide el número total de clasificaciones correctas dividido por el número total de casos.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$



- **Precisión:**

La precisión mide el número total de positivos verdaderos dividido por el número total de positivos predichos.

$$\text{Precision} = \frac{TP}{TP + FP} \quad \text{or} \quad \frac{\text{True Positive}}{\text{Predictive Results}}$$

	Matriz de confusión	
	33	25
	25	71
Exactitud:		67,53%
Precisión:		56,90%

- **Sensibilidad:**

El recuerdo/sensibilidad mide el número total de verdaderos positivos dividido por el número total de verdaderos positivos.

$$Recall = \frac{TP}{TP + FN} \quad \text{or} \quad \frac{\text{True Positive}}{\text{Actual Results}}$$

Exactitud:	67,53%
Precisión:	56,90%
Sensibilidad:	56,90%

- **Especificidad:**

La especificidad mide el número total de verdaderos negativos dividido por el número total de verdaderos negativos.

$$\textit{Specificity} = \frac{TN}{TN + FP}$$

	Matriz de confusión		
	33	25	
	25	71	
	Exactitud:	67,53%	
	Precisión:	56,90%	
	Sensibilidad:	56,90%	
	Especificidad:	73,96%	

- **Puntuación F1**

La puntuación F1 es una métrica única que es una media armónica de la precisión y la recuperación.

$$\textit{F - score} = \frac{2 * \textit{Recall} * \textit{Precision}}{\textit{Recall} + \textit{Precision}}$$


	Exactitud:	67,53%	
	Precisión:	56,90%	
	Sensibilidad:	56,90%	
	Especificidad:	73,96%	
	F1	0,568965517	

Un Score bastante justo...

Apartado 3: Aplica la técnica de aprendizaje no supervisado de Detección de Anomalías.


- Aplica el modelo de detección de anomalías en BigML dentro de las funciones rápidas de algoritmos no supervisados.

Ejecuto el apartado anomalías.




- Analiza las top 5 anomalías de tu problema y decide si merece la pena analizarlas a parte.

El top de cinco primeras anomalías.




Reviso las anomalías.



- Si crees que son importantes, crea un dataset con ellas para analizarlas

Al revisar las anomalías al final el porcentaje de la Diabetes es muy bajo.



- Si crees que son simplemente errores de medida, crea un dataset sin ellas.

