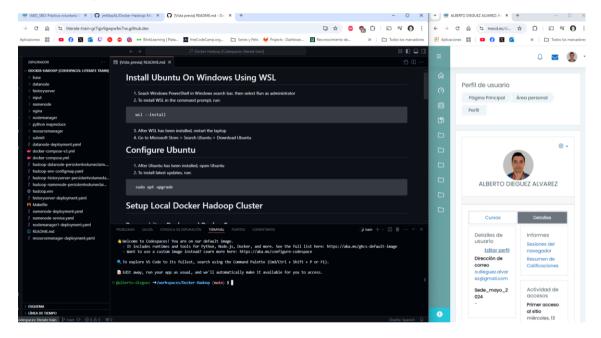
# Práctica voluntaria SBD02.a

## I. Preparación del entorno

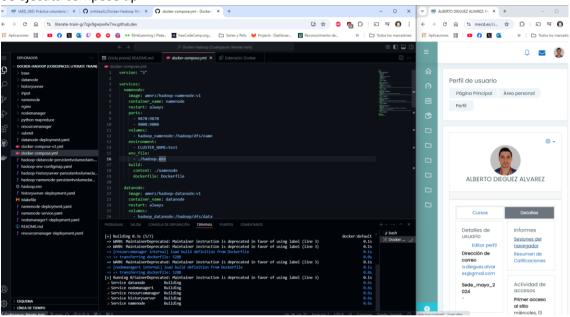
- Lo primero que haremos será hacer un fork del siguiente repositorio: <a href="https://github.com/jmfdiazAL/Docker-Hadoop">https://github.com/jmfdiazAL/Docker-Hadoop</a>, de esta manera, podemos conservar nuestros cambios. (En caso de que hayamos decidido usar una instalación local, clonaremos el repositorio anterior.)
- 2. Desde nuestro repositorio, pulsaremos en el botón <> **Code**, y luego seleccionaremos la pestaña **Codespaces**:
- 3. Ahora pulsamos en el botón **Create codespace on master**. Se nos abrirá una instancia en la nube con VS Code. (En el caso de usar un entorno local, simplemente abriremos el repositorio local con VS Code.)



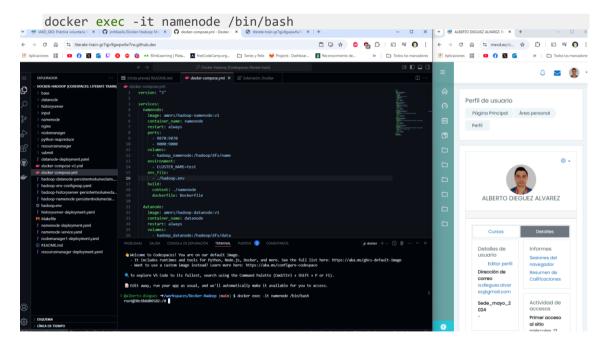
- 4. Si abrimos bien el archivo **docker-compose.yml** o **docker-compose-v3.yml**, se nos propone instalar el complemento de Docker, pulsamos el botón Instalar.
- 5. Como hemos mencionado en el punto anterior, disponemos de 2 archivos para Docker Compose:
  - 1. docker-compose-v3.yml, que utiliza las imágenes clásicas de Big Data Europe.
  - 2. **docker-compose.yml**, que utiliza unas imágenes basadas en las anteriores pero que nos van a permitir añadir Python como veremos en la última parteé.

- 6. A continuación, pulsamos sobre el archivo **docker-compose.yml** con el botón derecho, y en el menú contextual seleccionaremos **Compose Up**.
- 7. Se descargarán las imágenes correspondientes, y se levantará la pila de contenedores.

Se ejecuta compose up

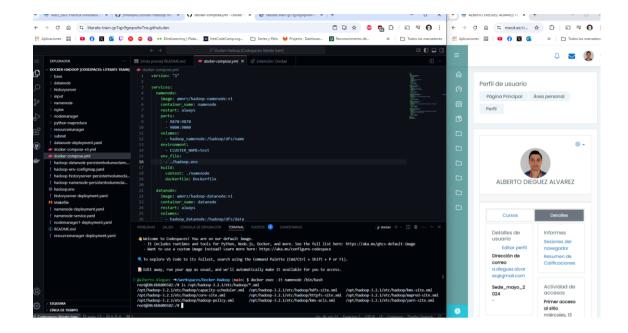


8. Ahora, en la ventana inferior de **Terminal**, introduciremos el comando siguiente para abrir un *shell* en el contenedor:



A partir de ahora, podemos entrar en la consola del clúster.

9. Con el siguiente comando, podemos ver todos los archivos de configuración: ls /opt/hadoop-3.2.1/etc/hadoop/\*.xml



### II. Crear un archivo en HDFS

En esta parte vamos a subir un archivo a HDFS y vamos a consultarlo desde la línea de comandos.

1. Creamos el directorio user/root/input:

hdfs dfs -mkdir -p /user/root/input

```
Welcome to Codespaces! You are on our default image.
- It includes runtimes and tools for Python, Node.js, Docker, and more. See the full list here: https://aka.ms/ghcs-default-image
- Want to use a custom image instead? Learn more here: https://aka.ms/configure-codespace

Q To explore VS Code to its fullest, search using the Command Palette (Cmd/Ctrl + Shift + P or F1).

Edit away, run your app as usual, and we'll automatically make it available for you to access.

Calberto-dieguez →/workspaces/Docker-Hadoop (main) $ docker exec -it namenode /bin/bash
root@30c6b8d06582:/# ls /opt/hadoop-3.2.1/etc/hadoop/*.xml /opt/hadoop-3.2.1/etc/hadoop/capacity-scheduler.xml /opt/hadoop-3.2.1/etc/hadoop/capacity-scheduler.xml /opt/hadoop-3.2.1/etc/hadoop/core-site.xml /opt/hadoop-3.2.1/etc/hadoop/mapred-site.xml /opt/hadoop-3.2.1/etc/hadoop/hadoop-policy.xml /opt/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/mapred-site.xml /opt/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/yarn-site.xml root@30c6b8d06582:/# hdfs dfs -mkdir -p /user/root/input
```

2. Copiamos los archivos xml de configuración en el directorio de entrada:

hdfs dfs -put \$HADOOP\_HOME/etc/hadoop/\*.xml /user/root/input

```
/opt/hadoop-3.2.1/etc/hadoop/capacity-scheduler.xml /opt/hadoop-3.2.1/etc/hadoop/httpfs-site.xml /opt/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/httpfs-site.xml /opt/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/hadoop-3.2.1/etc/hadoop/httpfs-site.xml /opt/hadoop-3.2.1/etc/hadoop/mapred-site.xml /opt/hadoop-3.2.1/etc/hadoop/sms-site.xml /opt/hadoop-3.2.1/etc/hadoop/sms-acls.xml /opt/hadoop-3.2.1/etc/hadoop/yarn-site.xml root@30c6b8d06582:/# hdfs dfs -mkdir -p /user/root/input root@30c6b8d06582:/# hdfs dfs -put $\frac{\text{yHQDOOP}}{\text{HQDOOP}} \text{+NNI} /\text{user/root/input} /\text{voot/input} \text{2024-12-23} \text{00:18:58,484} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:58,580} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,349} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,349} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,349} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,369} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,369} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,788} \text{INFO} \text{sal.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 \text{00:18:59,788} \text{INFO} \text{sal.SaslDataTr
```

3. Creamos el archivo **data.txt**: en el directorio actual, y lo cargamos con valores de ejemplo:

**curl** <a href="https://raw.githubusercontent.com/jmfdiazAL/ooxwv-docker">https://raw.githubusercontent.com/jmfdiazAL/ooxwv-docker</a> hadoop/master/SampleMapReduce.txt --output data.txt

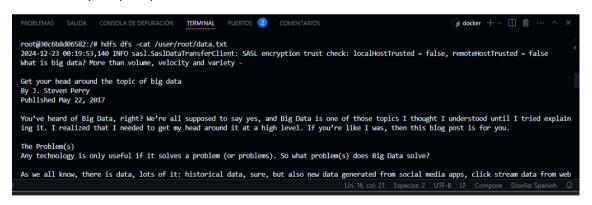
```
2024-12-23 00:18:58,508 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:18:58,928 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:18:59,309 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:18:59,309 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:18:59,788 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:18:59,808 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:18:59,808 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false 2024-12-23 00:19:00,228 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrus
```

4. Copiamos el archivo data.txt en el directorio user/root:

hdfs dfs -put data.txt /user/root/

5. Verificamos que el contenido se ha copiado en HDFS:

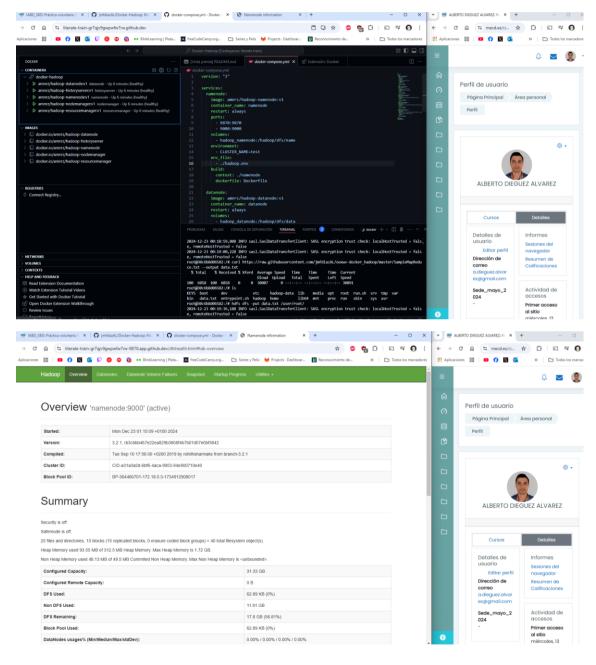
#### hdfs dfs -cat /user/root/data.txt



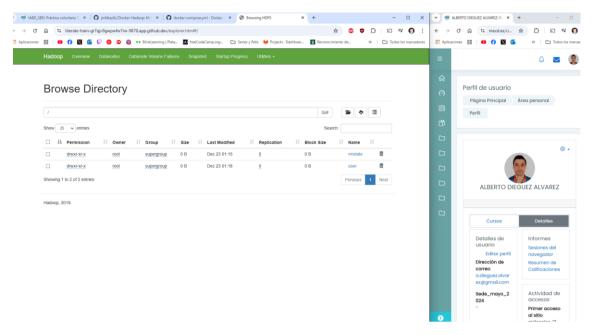
### III. Ver en HDFS

En la tercera parte, vamos a ver los archivos subidos a HDFS en la interfaz gráfica.

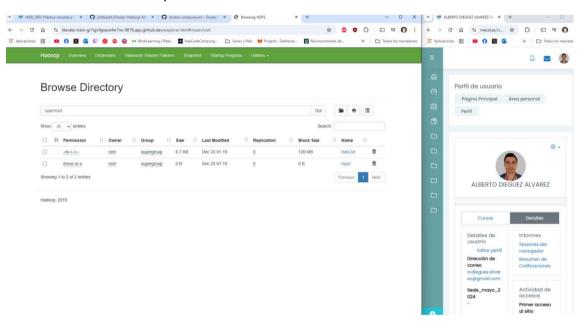
1. Pulsamos en la pestaña lateral en la extensión Docker, se nos mostrará la pila de contenedores ejecutándose y, pasando el ratón por encima del contenedor de nombre namenode, se abrirá un recuadro con los puertos disponibles y seleccionaremos el puerto 9870. También podemos abrir el menú contextual que se despliega con el botón derecho, sobre el mismo contenedor y pulsar la opción Open in Browser, y elegir el mismo puerto. Se nos abrirá una nueva ventana con la interfaz gráfica de nuestro clúster.



2. A continuación, pulsamos en la opción Utilities y en Browse the file system:

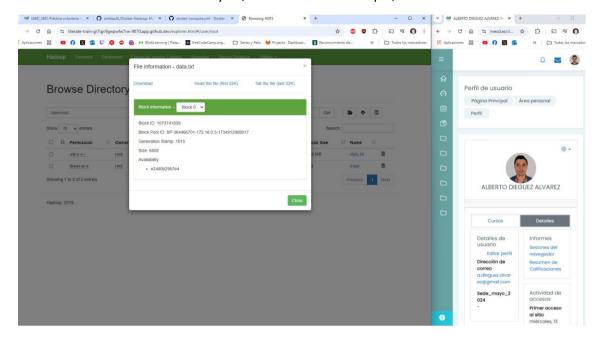


3. Pulsamos en user y en root:



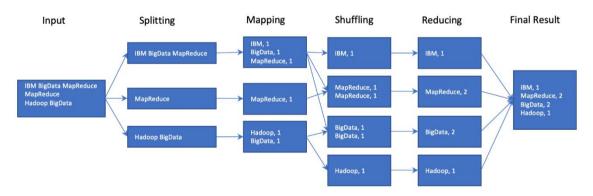
4. Observa que el tamaño del bloque es de 128 MB, aunque el tamaño del archivo es en realidad mucho más pequeño. Esto se debe a que el tamaño de bloque predeterminado utilizado por HDFS es 128 MB.

5. Puedes hacer click en el archivo para revisarlo. Nos da información sobre el archivo en términos de número de bytes, identificación de bloque, etc.



# IV. Ejecutar un ejemplo MapReduce para contar palabras

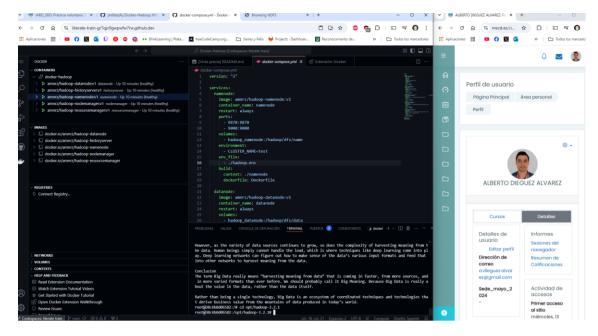
En este apartado vamos a ver una operación sencilla MapReduce sobre un archivo de ejemplo. En la siguiente imagen se puede ver un resumen del procesamiento.



Para ello seguiremos los pasos:

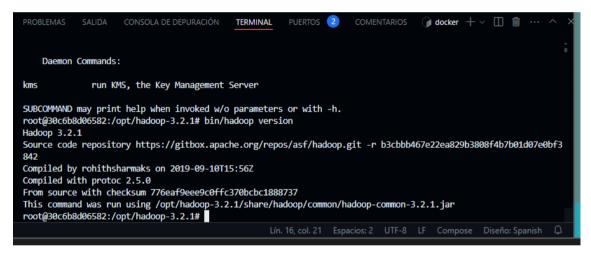
1. Nos movemos al directorio opt/hadoop-3.2.1:

cd opt/hadoop-3.2.1



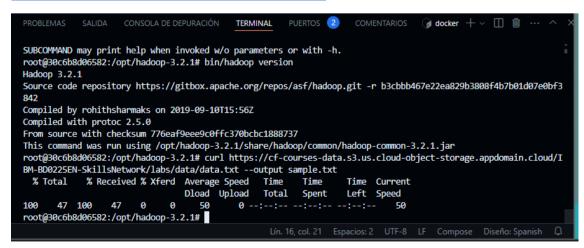
2. Chequeamos la versión de Hadoop:

#### bin/hadoop versión



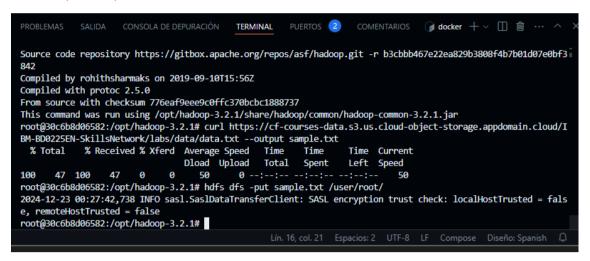
3. Nos bajamos un archivo de prueba sample.txt:

**curl** <a href="https://cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud/IBM-BD0225EN-SkillsNetwork/labs/data/data.txt --output sample.txt">https://cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud/IBM-BD0225EN-SkillsNetwork/labs/data/data.txt --output sample.txt</a>



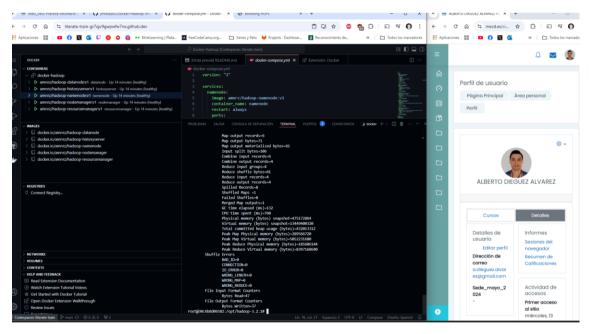
4. Cargamos el archivo sample.txt en HDFS:

hdfs dfs -put sample.txt /user/root/



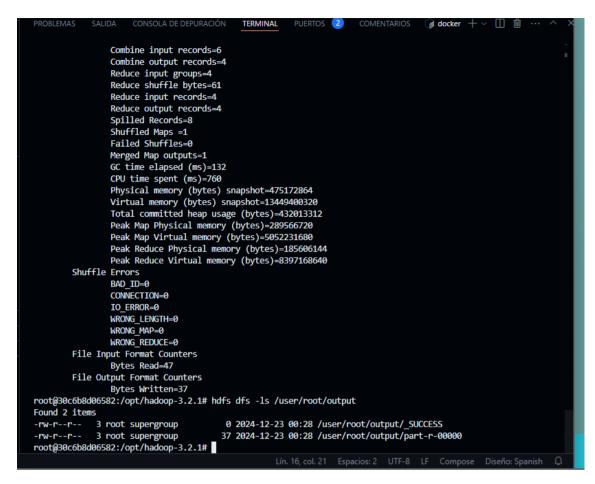
5. Ejecutamos el archivo Java compilado de ejemplo para contar palabras con MapReduce, y copiamos la salida en el directorio /user/root/output:

bin/hadoop jar share/hadoop/mapreduce/hadoop-mapreduce-examples-3.2.1.jar wordcount sample.txt output



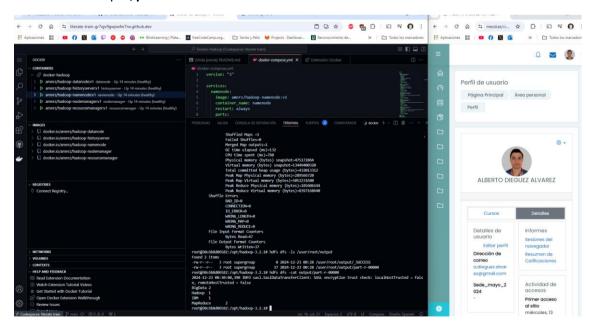
6. Una vez haya terminado la ejecución, vemos los archivos generados en el directorio de salida:

hdfs dfs -ls /user/root/output



7. Vemos la salida consultando el archivo part-r-00000:

hdfs dfs -cat output/part-r-00000

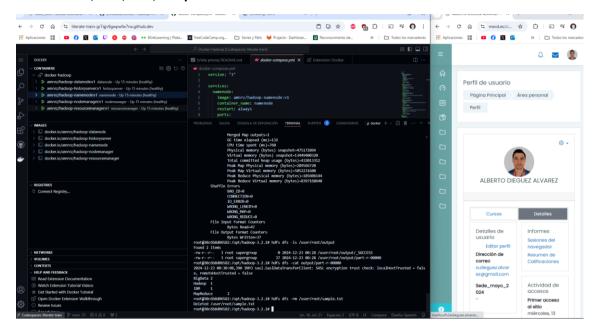


8. Nos mostrará una salida parecida a la siguiente:

2024-12-20 20:52:01,009 INFO sasl.SaslDataTransferClient: SASL encryption trust check:
localHostTrusted = false, remoteHostTrusted = false
BigData 2
Hadoop 1
IBM 1
MapReduce 2

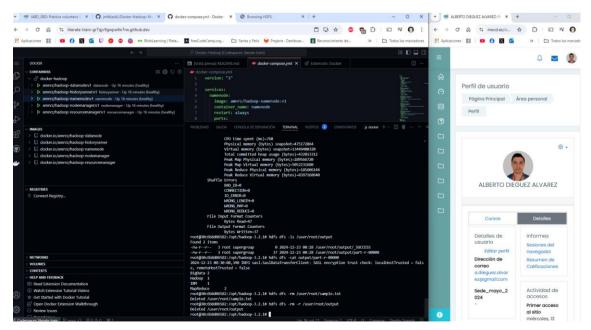
9. Para finalizar, podemos eliminar el archivo sample.txt:

### hdfs dfs -rm /user/root/sample.txt



10. Y el directorio /user/root/output:

### hdfs dfs -rm -r /user/root/output

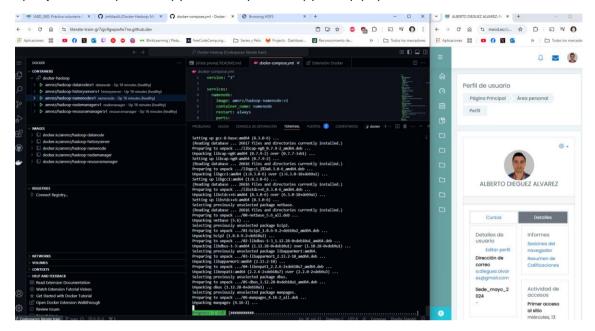


# V. Acceso mediante Python

En este apartado vamos a usar el paquete **snakebite** para acceder a HDFS mediante Python:

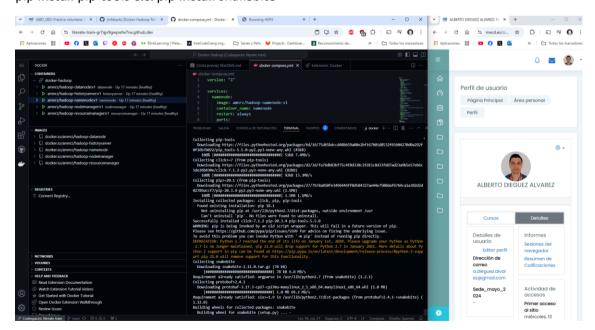
1. En la consola del contenedor **namenode** que hemos venido utilizando hasta ahora, escribiremos:

apt update && apt install python && apt install python-pip -y

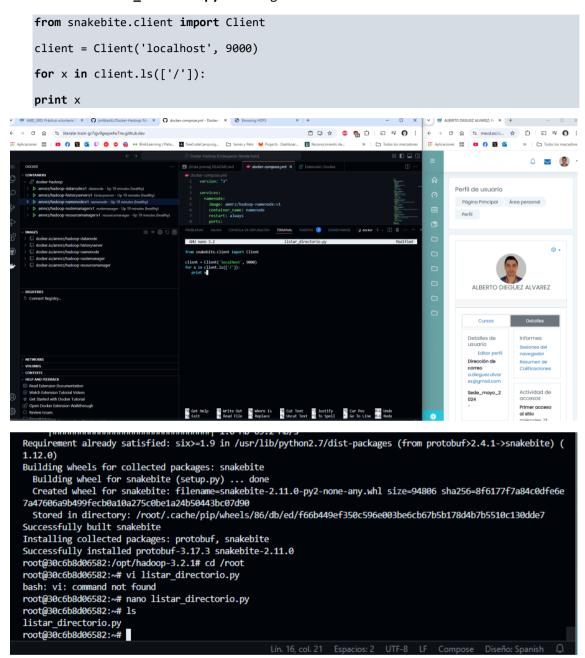


2. Instalamos con pip los paquetes necesarios:

pip install pip-tools && pip install snakebite



 Nos movemos al directorio /root por ejemplo y creamos el fichero listar\_directorio.py con el siguiente contenido:

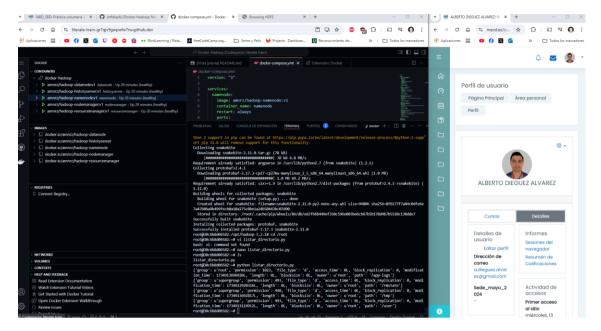


4. Si ejecutamos el archivo anterior, podremos ver la siguiente salida:

root@83e2d8f60697:~# python listar\_directorio.py

```
{'group': u'supergroup', 'permission': 493, 'file_type': 'd', 'access_time': 0L, 'block_replication': 0, 'modification_time': 1734798473139L, 'length': 0L, 'blocksize': 0L, 'owner': u'root', 'path': '/rmstate'}

{'group': u'supergroup', 'permission': 493, 'file_type': 'd', 'access_time': 0L, 'block_replication': 0, 'modification_time': 1734800493043L, 'length': 0L, 'blocksize': 0L, 'owner': u'root', 'path': '/user'}
```



5. Podemos probar el resto de código que aparece en la unidad para crear directorios, eliminar ficheros y directorios, copiar ficheros de HDFS a local y mostrar el contenido de ficheros HDFS.

Con esta práctica hemos realizado una pequeña introducción a HDFS.